

Guía de actividad evaluativa
Optimización de rutas de última milla con datos de Kaggle
Caso LogiExpress

Programa	Tecnología en Desarrollo de Software
Asignatura	Electiva Técnica II - Ciencia de Datos
Semestre	Séptimo semestre
Modalidad de trabajo	Grupos de máximo dos estudiantes
Herramienta principal	Google Colaboratory o Jupyter Notebook
Lenguaje	Python
Producto base	Notebook <code>Optimizacion_Rutasv3.ipynb</code>

1. Contexto de la actividad

Este documento tiene como propósito complementar y ampliar la descripción de la actividad sobre el caso aplicado de optimización de rutas de última milla para una empresa ficticia denominada LogiExpress; propuesta para las semanas 14-16 del curso. Recuerden que en el archivo de Jupyter Notebook compartido previamente, se brindaron las directrices incluyendo código funcional, así como los requerimientos para el desarrollo de la actividad. Esta actividad presenta el caso aplicado de una empresa que debe organizar la entrega de pedidos desde un depósito central hacia diferentes clientes, considerando la ubicación geográfica de cada pedido y una capacidad máxima de carga por vehículo.

Del enunciado explicado en el Jupyter Notebook, se infiere que, el ejercicio no se limita a ejecutar un algoritmo sobre datos simulados. Implica entonces la construcción de un flujo completo de trabajo en ciencia de datos aplicada; búsqueda de datos, preparación del dataset, limpieza de registros, cálculo de distancias geográficas, análisis de complejidad, construcción de rutas y discusión de los resultados obtenidos. Esta actividad permite articular tres momentos del curso. En la semana 14 se trabaja la búsqueda y preparación de datos desde Kaggle; en la semana 15 se analiza la complejidad computacional y las limitaciones de la fuerza bruta; en la semana 16 se implementan heurísticas de optimización para construir rutas factibles.

2. Objetivos de aprendizaje

Al finalizar la actividad, el estudiante deberá estar en capacidad de:

1. Buscar y preparar un dataset de Kaggle relacionado con comercio electrónico, entregas, logística o movilidad.
2. Construir un subconjunto mínimo de 30 ubicaciones reales de entrega con latitud y longitud.
3. Calcular una matriz de distancias utilizando la fórmula de Haversine.
4. Explicar por qué la fuerza bruta no es una estrategia viable cuando aumenta el número de pedidos.
5. Construir rutas de entrega respetando una restricción de capacidad máxima por vehículo.

6. Aplicar heurísticas sencillas, como vecino más cercano y 2-opt, para mejorar una solución inicial.
7. Presentar resultados mediante tablas, gráficos, mapas y una sustentación técnica.

3. Dataset de trabajo

El notebook base utiliza como referencia el dataset [Brazilian E-Commerce Public Dataset by Olist](#), disponible en Kaggle. Este dataset contiene información de pedidos, clientes, productos, items de pedidos y geolocalización aproximada por prefijo postal.

Cada grupo puede utilizar el dataset sugerido u otro dataset de Kaggle, siempre que cumpla las siguientes condiciones mínimas:

- Estar relacionado con comercio electrónico, entregas, logística, movilidad o distribución urbana.
- Permitir construir al menos 30 ubicaciones de entrega reales o aproximadas.
- Contener coordenadas geográficas o variables que permitan obtener latitud y longitud.
- Permitir construir una variable de peso, demanda, volumen o carga asociada a cada pedido.

En caso de usar el dataset Olist, el grupo debe trabajar principalmente con los siguientes archivos:

Archivo	Uso dentro de la actividad
<code>olist_orders_dataset.csv</code>	Identificar pedidos y estado de entrega.
<code>olist_customers_dataset.csv</code>	Asociar los pedidos con clientes y prefijos postales.
<code>olist_order_items_dataset.csv</code>	Relacionar pedidos con productos comprados.
<code>olist_products_dataset.csv</code>	Obtener el peso de los productos.
<code>olist_geolocation_dataset.csv</code>	Obtener latitud y longitud asociadas a prefijos postales.

4. Parámetros mínimos del notebook

El notebook base deja configuradas variables de control para facilitar la ejecución inicial. Durante la explicación en clase se puede ejecutar el notebook con pocos registros. Para la entrega final, el grupo debe modificar la variable correspondiente para trabajar con mínimo 30 pedidos.

```
capacidad_vehiculo_kg = 100
numero_pedidos_a_cargar = 30
minimo_pedidos_entrega_final = 30
```

La capacidad de referencia será de 100 kg por vehículo. Si el grupo modifica este valor, debe justificarlo en el informe y explicar cómo afecta el número de rutas generadas.

5. Desarrollo de la actividad

5.1. Fase 1. Preparación y búsqueda de datos en Kaggle

Esta fase corresponde al componente de la semana 14. El grupo debe buscar, descargar y preparar el dataset de trabajo. Si se usa el dataset Olist, el notebook base ya incluye el código inicial para cargar las tablas principales y construir la tabla mínima requerida para el problema.

El grupo debe dejar evidencia de los siguientes aspectos:

1. Nombre del dataset utilizado.
2. Enlace o referencia al dataset en Kaggle.
3. Breve descripción del origen de los datos.
4. Tablas originales utilizadas.
5. Número de registros originales y número de registros disponibles después de limpieza.
6. Criterio usado para seleccionar los 30 pedidos.
7. Validación de registros nulos, duplicados o con coordenadas erróneas.

La tabla mínima para continuar con el problema de rutas debe contener las siguientes variables:

Variable	Descripción
Pedido_ID	Identificador único del pedido.
Latitud	Coordenada geográfica del punto de entrega.
Longitud	Coordenada geográfica del punto de entrega.
Peso_kg	Peso estimado del pedido en kilogramos.
Ciudad	Ciudad asociada al punto de entrega, cuando esté disponible.
Estado	Estado, departamento o región, cuando esté disponible.

No se acepta como entrega final el uso exclusivo del dataset de demostración incluido en el notebook. Ese dataset solo se usa para validar que el código funcione en clase cuando no se tengan todavía los archivos descargados desde Kaggle.

5.2. Fase 2. Cálculo de distancias con Haversine

Una vez construida la tabla de pedidos, el grupo debe calcular la matriz de distancias entre el depósito y todos los puntos de entrega. Para ello debe usar la fórmula de Haversine, que estima la distancia entre dos coordenadas geográficas considerando la curvatura de la Tierra.

La distancia entre dos puntos se define como:

$$d = 2R \arcsin \left(\sqrt{\sin^2 \left(\frac{\varphi_2 - \varphi_1}{2} \right) + \cos(\varphi_1) \cos(\varphi_2) \sin^2 \left(\frac{\lambda_2 - \lambda_1}{2} \right)} \right)$$

Donde:

- R corresponde al radio aproximado de la Tierra en kilómetros.
- φ_1 y φ_2 son las latitudes de los dos puntos en radianes.
- λ_1 y λ_2 son las longitudes de los dos puntos en radianes.

El grupo debe exportar o mostrar la matriz de distancias y explicar por qué esta matriz es necesaria antes de construir las rutas.

5.3. Fase 3. Análisis de complejidad y fuerza bruta acotada

Esta fase corresponde al componente de la semana 15. El grupo debe ejecutar el experimento de fuerza bruta únicamente con subconjuntos pequeños de pedidos. El propósito no es resolver 30 pedidos por fuerza bruta, sino evidenciar el crecimiento del tiempo de ejecución.

Se espera que el grupo:

1. Ejecute pruebas con diferentes tamaños pequeños de pedidos, por ejemplo entre 3 y 9 pedidos.
2. Registre el tiempo de ejecución para cada tamaño evaluado.
3. Construya una gráfica de tiempo de ejecución.
4. Explique el crecimiento combinatorio o factorial del problema.
5. Justifique por qué se requieren heurísticas para escenarios con más pedidos.

El grupo no debe forzar la ejecución de fuerza bruta con 30 pedidos, porque esto puede bloquear el entorno de Colab o generar tiempos de ejecución no razonables.

5.4. Fase 4. Construcción de rutas por capacidad

Esta fase corresponde al componente de la semana 16. A partir de los pedidos seleccionados, el grupo debe construir rutas de entrega respetando la capacidad máxima del vehículo.

El notebook base propone una estrategia sencilla de agrupamiento por capacidad. Cada ruta debe cumplir la siguiente restricción:

$$\sum_{i \in r} \text{Peso}_i \leq \text{Capacidad_vehiculo}$$

Para esta actividad, la capacidad de referencia es:

$$\text{Capacidad_vehiculo} = 100 \text{ kg}$$

El grupo debe presentar una tabla resumen con, al menos, los siguientes campos:

- número de vehículo o ruta;

- cantidad de pedidos asignados;
- peso total de la ruta;
- distancia obtenida con vecino más cercano;
- distancia obtenida después de aplicar 2-opt;
- mejora en kilómetros.

5.5. Fase 5. Vecino más cercano y mejora local con 2-opt

Después de formar los grupos de pedidos por capacidad, el grupo debe ordenar cada ruta usando vecino más cercano y luego mejorarla mediante 2-opt.

La solución debe incluir:

1. Ruta inicial generada con vecino más cercano.
2. Ruta mejorada con 2-opt.
3. Comparación entre la distancia inicial y la distancia optimizada.
4. Discusión sobre la diferencia entre solución óptima y solución heurística.

Es importante aclarar que 2-opt no garantiza encontrar la mejor ruta posible, pero permite mejorar una solución inicial de forma sencilla y computacionalmente viable.

5.6. Fase 6. Visualización de resultados

El grupo debe presentar los resultados mediante tablas, gráficos y mapas. Como mínimo, se espera:

- tabla final de pedidos utilizados;
- matriz de distancias o una muestra representativa de esta matriz;
- gráfica de tiempo de ejecución de la fuerza bruta;
- tabla resumen de rutas;
- gráfico de distancia por vehículo;
- mapa final con las rutas diferenciadas por color.

6. Entregables

Cada grupo debe entregar en Classroom o en el medio definido por el docente los siguientes elementos:

1. Notebook de Jupyter ejecutado, limpio y documentado.
2. Enlace a repositorio GitHub con el notebook y archivos de apoyo.

3. Archivo CSV final con los pedidos utilizados, mínimo 30 registros.
4. Archivo CSV o tabla visible con la matriz de distancias Haversine.
5. Evidencia del dataset de Kaggle usado, incluyendo enlace y descripción.
6. Informe corto dentro del notebook o documento complementario con análisis y conclusiones.
7. Mapa final de rutas generado en el notebook.

El informe debe estar organizado al nivel de ingeniería, con buena ortografía, nombres completos de los integrantes y explicación técnica de las decisiones tomadas.

7. Estructura mínima del informe

El informe o sección final del notebook debe contener la siguiente estructura:

1. Descripción del problema.
2. Descripción del dataset utilizado.
3. Preparación y limpieza de datos.
4. Construcción de las 30 ubicaciones de entrega.
5. Cálculo de la matriz de distancias con Haversine.
6. Análisis de complejidad y resultados de fuerza bruta acotada.
7. Construcción de rutas con restricción de capacidad.
8. Comparación entre vecino más cercano y 2-opt.
9. Visualización y análisis del mapa final.
10. Limitaciones del ejercicio.
11. Conclusiones.

8. Rúbrica de evaluación

Criterio	Descripción	Porcentaje
Ingeniería de datos con Kaggle	Búsqueda del dataset, carga de archivos, integración de tablas, limpieza, validación de coordenadas, construcción de mínimo 30 ubicaciones reales y documentación del origen de los datos.	25 %

Cálculo de distancias y análisis de complejidad	Implementación correcta de Haversine, construcción de la matriz de distancias, experimento de fuerza bruta acotada, gráfica de tiempos y explicación del crecimiento combinatorio o factorial.	25 %
Implementación algorítmica	Construcción de rutas respetando capacidad de 100 kg, aplicación de vecino más cercano, mejora con 2-opt, generación de tabla resumen y comparación técnica de resultados.	35 %
Sustentación oral	Claridad en la explicación del código, defensa de decisiones de diseño, comprensión de limitaciones del modelo y respuesta a preguntas del docente.	15 %

9. Escala cualitativa sugerida

Nivel	Descripción
Excelente	El grupo cumple todos los requerimientos, usa datos reales de Kaggle, explica con claridad el proceso y sustenta adecuadamente las decisiones técnicas.
Bueno	El grupo cumple los elementos centrales, aunque presenta oportunidades menores de mejora en documentación, análisis o visualización.
Aceptable	El grupo logra una solución funcional, pero con debilidades relevantes en preparación de datos, explicación de complejidad o interpretación de resultados.
Insuficiente	El grupo no cumple el mínimo de datos reales, no ejecuta adecuadamente el notebook o no logra explicar técnicamente la solución presentada.

10. Preguntas orientadoras para la sustentación

Durante la sustentación se podrán formular preguntas como las siguientes:

1. ¿Por qué el dataset original de Kaggle no se podía usar directamente sin preparación?
2. ¿Qué tablas se tuvieron que unir para construir las ubicaciones de entrega?
3. ¿Qué criterios se usaron para seleccionar los 30 pedidos?
4. ¿Por qué se usó Haversine y qué limitaciones tiene frente a la distancia real por calles?
5. ¿Por qué no es viable resolver todos los pedidos por fuerza bruta?
6. ¿Qué diferencia hay entre una solución óptima y una solución heurística?
7. ¿Cómo se verifica que una ruta no supere la capacidad máxima del vehículo?
8. ¿Qué mejoras tendría que incorporar el modelo si se quisiera aproximar a un caso real de operación logística?

9. ¿Qué cambiaría si se procesaran 10.000 pedidos en lugar de 30?

11. Checklist antes de entregar

Antes de realizar la entrega, el grupo debe verificar que:

- la variable `numero_pedidos_a_cargar` está configurada en 30 o más;
- el notebook se ejecuta de principio a fin sin errores;
- se usaron datos reales de Kaggle y no únicamente el dataset demo;
- se muestra la tabla final de pedidos;
- se muestra o exporta la matriz de distancias;
- se presenta la gráfica del análisis de complejidad;
- se presenta la tabla resumen de rutas;
- se presenta el mapa final;
- el informe incluye análisis y no solo capturas de pantalla;
- todos los integrantes aparecen identificados con nombres completos.

12. Observación final

No se evaluará únicamente que el código ejecute. También se evaluará que el grupo comprenda el problema de optimización, justifique las decisiones de preparación de datos, explique la complejidad del enfoque de fuerza bruta y reconozca las limitaciones de las heurísticas utilizadas.

Nota de cierre del profesor. Aunque el notebook base proporciona una parte importante del código requerido para el desarrollo de la actividad, su realización exige comprensión, ajuste, ejecución, análisis e interpretación de resultados. Por lo tanto, en la evaluación se priorizará la coherencia entre el entregable presentado y la evidencia de apropiación conceptual y técnica demostrada durante la sesión de sustentación. Por lo tanto, el entregable puede estar completo, pero si los estudiantes no pueden sustentarlo correctamente, el trabajo que haya entregado pierde toda validez y la calificación será cero.